

SOAL UJIAN AKHIR SEMESTER

PROGRAM KMMI

Nama : Andi Illa Erviani Nensi
Kelas : DS02
NIM : 200102502002
No urut absen : 10

Soal

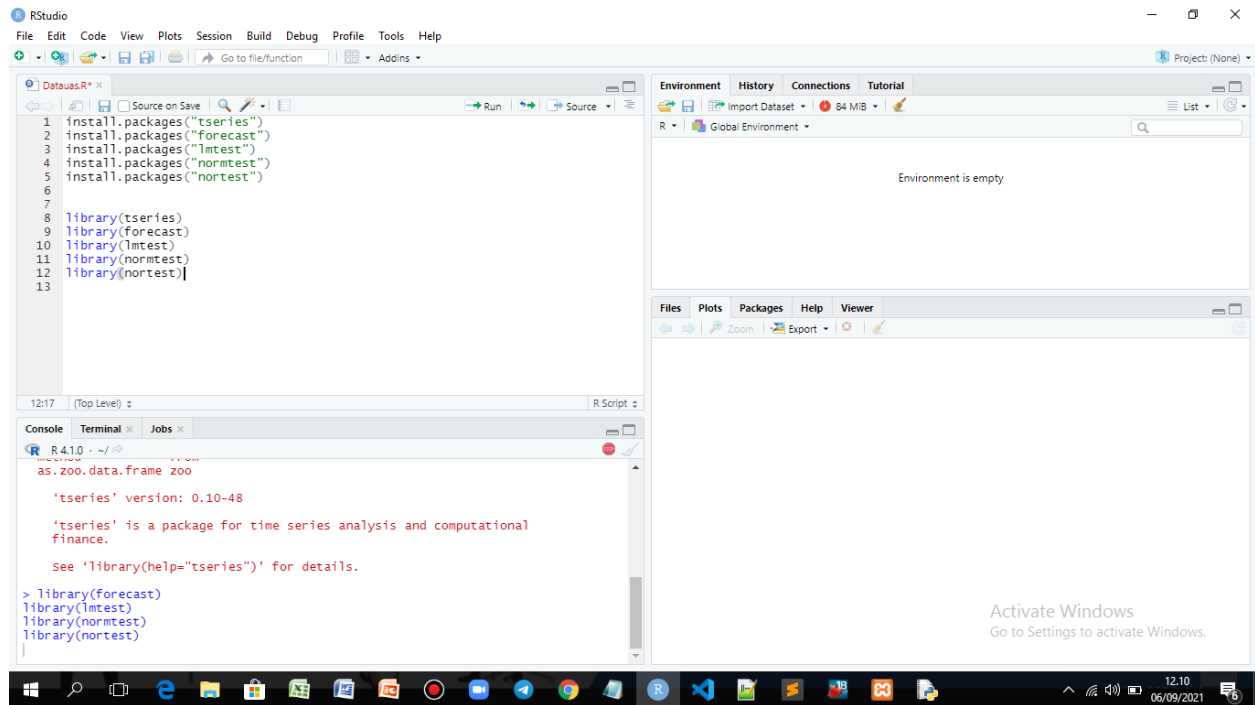
Diberikan data deret waktu tentang **produksi susu** yang dicatat tiap bulan mulai Januari sampai Desember selama 14 tahun (Data terlampir). Diasumsikan bahwa residual dari model telah berdistribusi normal:

- a. Lakukan metodologi Box-Jenkins untuk menentukan model ARIMA terbaik yang sesuai untuk data tersebut! APakah data tersebut sudah stasioner dalam variansi? Tuliskan nilai Boxcox.lambda yang diperoleh! Lampirkan hasil komputer yang diperoleh!
- b. Lakukan peramalan untuk menentukan nilai-nilai 12 tahap ke depan!

Jawab

1. Input Data

Berikut ini diberikan langkah-langkah analisis deret waktu dengan menggunakan R Studio. Packages yang harus di intsal yaitu sebagai berikut:



Langkah pertama adalah input data di R dengan data terurut sesuai waktu dan memanjang ke bawah. Dengan syntax:

```
15 #input data setwd("D:/KMMI")
16
17 setwd("E:/UASKU")
18 data <-read.csv("data1.csv", sep=";")
19 data1 <- data
20 data1
21 data1 = data.frame(data1)
22 head(data)
23 tail(data)
24
```

Sehingga tampil hasilnya sebagai berikut:

```
> setwd("E:/UASKU")
> setwd("E:/UASKU")
> data <- read.csv("data1.csv", sep=";")
> data1 <- data
> data1
```

	t	Zt
1	1	590
2	2	562
3	3	641
4	4	657
5	5	728
6	6	698
7	7	641
8	8	600
9	9	569
10	10	578
11	11	554
12	12	583
13	13	601
14	14	567
15	15	654
16	16	674
17	17	743
18	18	717
19	19	661
20	20	618
21	21	584
22	22	588
23	23	566
24	24	599
25	25	629
26	26	619
27	27	689
28	28	706

```

148 148 903
149 149 970
150 150 948
151 151 909
152 152 868
153 153 816
154 154 813
155 155 774
156 156 814
157 157 835
158 158 783
159 159 893
160 160 904
161 161 967
162 162 938
163 163 897
164 164 859
165 165 818
166 166 828
167 167 798
168 168 844
> data1 = data.frame(data1)
> head(data)
  t  Zt
1 1 590
2 2 562
3 3 641
4 4 657
5 5 728
6 6 698
> tail(data)
  t  Zt
163 163 897
164 164 859
165 165 818
166 166 828
167 167 798
168 168 844

```

2. Tahap Identifikasi

Langkah pertama yang dilakukan dalam pemodelan deret waktu adalah tahap identifikasi. Pada tahap identifikasi ini, hal yang dilakukan adalah memeriksa kestasioneran data baik dalam mean maupun dalam variansi. Kestasioneran data dalam rata-rata dapat diperiksa melalui plot time series secara visual atau melalui uji Augmented Dickey-Fuller. Karena data terdiri dari dua variabel yaitu t sebagai variabel waktu dan Z_t sebagai data deret waktu penjualan, maka untuk kemudahan, kita dapat melabel data Z_t dengan nama penjualan:

```

> Penjualan <- data1$Zt
> Minggu <- data1$t


```

Sehingga perintah untuk plot time series adalah:

```


> ts.plot (Penjualan)

```




```
> act(Penjualan)
```

Series Penjualan



```
> pacf(Penjualan)
```

Series Penjualan



Mengecek Kestasioneran data sebagai berikut:

```
> #Cek kestasioneran data
> adf.test(Penjualan, alternative = "stationary", k = 12)

      Augmented Dickey-Fuller Test

data:  Penjualan
Dickey-Fuller = -2.0731, Lag order = 12, p-value = 0.5458
alternative hypothesis: stationary

> |
```

Dari hasil pengujian uji ADF diperoleh nilai p-value = 0,5458 yang berarti bahwa hipotesis H_0 ditolak, alternative hypothesis: stasionary diterima. Ini berarti bahwa data tersebut sudah stasioner dalam rata-rata. Ada perbedaan kesimpulan yang dihasilkan mengenai kestasioneran data dengan berdasarkan plot time series dan plot ACF dan dengan berdasarkan ADF test. Tetapi jelas terlihat dari plot time series dan plot ACF bahwa data belum stasioner baik dalam rata-rata non musiman maupun dalam rata-rata musiman. Nah, oleh karena itu, langkah berikutnya adalah melakukan differencing 1 non musiman terlebih dahulu, lalu melihat kembali plot time series maupun plot ACF hasil differencing nya.

```

> #differencing 1 non musiman dengan beberapa cara
> differencing1 <- diff(Penjualan, differences = 1)
> differencing1
 [1] -28  79  16  71 -30 -57 -41 -31  9 -24  29  18 -34  87  20  69 -26 -56 -43 -34  4 -22  33
[24]  30 -10  70  17  65 -34 -58 -39 -35  7 -17  40  24 -36  87  13  60 -26 -54 -49 -38  6 -19
[47]  33  42 -42 101  19  56 -13 -63 -38 -36  6 -22  43  25 -46  95  22  53 -20 -50 -45 -41  6
[70] -27  38  19 -21  79  21  62 -32 -43 -43 -39  5 -29  34  23 -44  95  20  66 -26 -44 -37 -39
[93]  -2 -33  44  16 -43 100  17  62 -27 -40 -36 -43  7 -36  40  53 -48 104  18  64 -29 -44 -35
[116] -44  10 -37  37  26 -27  91  10  61 -26 -41 -39 -46  1 -44  39  16 -48 110  15  59 -33 -43
[139] -44 -53  7 -31  42  26 -50 111  13  67 -22 -39 -41 -52 -3 -39  40  21 -52 110  11  63 -29
[162] -41 -38 -41  10 -30  46
>


```

Berikut hasil plot dari time series differencing 1 non musiman:

```

> ts.plot(differencing1)

```




Plot ACF hasil differencing 1 non musiman sebagai berikut:

```

> acf(differencing1)


```

Series differencing1



```
> pacf(differencing1)
```

Series differencing1



Berdasarkan plot time series dan plot ACF serta PACF dari data hasil differencing 1 non musiman, dapat disimpulkan bahwa data belum stasioner dalam rata-rata musiman. Nilai ACF pada lag musiman kelipatan 12 cenderung turun lambat. Sehingga diperlukan proses differencing 1 musiman 12 dari data hasil differencing satu non musiman.

Syntax:

```
45 #differencing 1 musiman 12 dari data yang sudah dilakukan differencing 1 non musiman
46 #dapat diketahui bahwa diff(differencing1, differencing = 12), hasilnya akan berbeda dengan diff(differencing1, lag = 12)
47 diffnonmus_mus12 <- diff(differencing1, lag = 12)
48 diffnonmus_mus12
```



Sehingga dihasilkan:

```
> #dapat diketahui bahwa diff(differencing1, differencing = 12), hasilnya akan berbe
da dengan diff(differencing1, lag = 12)
> diffnonmus_mus12 <- diff(differencing1, lag = 12)
> diffnonmus_mus12
 [1] -6  8  4 -2  4  1 -2 -3 -5  2  4 12 24 -17 -3 -4 -8 -2  4
[20] -1  3  5  7 -6 -26 17 -4 -5  8  4 -10 -3 -1 -2 -7 18 -6 14
[39]  6 -4 13 -9 11  2  0 -3 10 -17 -4 -6  3 -3 -7 13 -7 -5  0
[58] -5 -5 -6 25 -16 -1  9 -12  7  2  2 -1 -2 -4  4 -23 16 -1  4
[77]  6 -1  6  0 -7 -4 10 -7  1  5 -3 -4 -1  4  1 -4  9 -3 -4
[96] 37 -5  4  1  2 -2 -4  1 -1  3 -1 -3 -27 21 -13 -8 -3  3  3
[115] -4 -2 -9 -7  2 -10 -21 19  5 -2 -7 -2 -5 -7  6 13  3 10 -2
[134]  1 -2  8 11  4  3  1 -10 -8 -2 -5 -2 -1 -2 -4 -7 -2  3 11
[153] 13  9  6
```


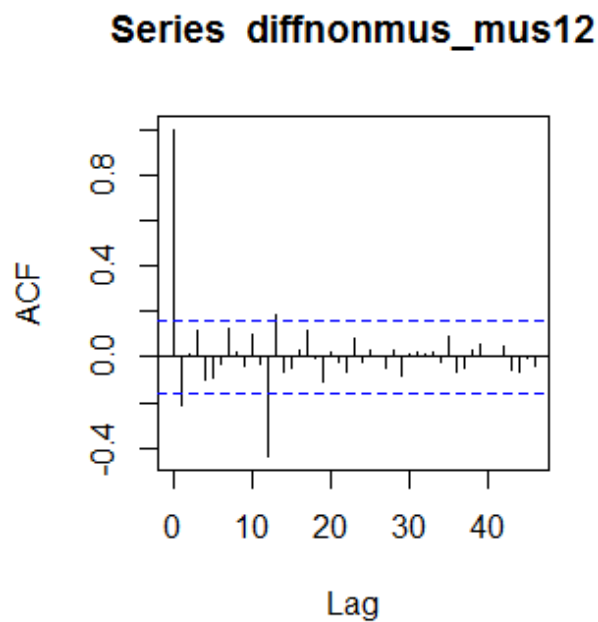
Berikutnya dilakukan plot time series atau ditampilkan plot time series, plot ACF hasil differencing non musiman dan musiman. Dengan syntax:

```
50 #plot time series, plot ACF data hasil differencing non musiman & musimants.
51 plot(diffnonmus_mus12)
52 ts.plot(diffnonmus_mus12)
53 par(mfrow=c(1,2))
54 acf(diffnonmus_mus12,lag.max=46)
55 pacf(diffnonmus_mus12,lag.max=46)
56
```

Hasilnya yaitu sebagai berikut:



Untuk plot acf dan pacf:



Berdasarkan plot ACF dan plot PACF dari data hasil differencing 1 non musiman dan differencing 1 musiman 12, dapat dilihat bahwa plot ACF terpotong setelah lag 1 (cut off after lag 1) pada lag non-musiman, dan terpotong setelah lag musiman 12 sedangkan plot PACF pada lag non musiman turun secara eksponensial (dies down), dan plot PACF terpotong setelah lag 1 (cut off after lag 1) pada lag musiman 12. Berdasarkan teori yang telah dibahas,

dapat disimpulkan bahwa beberapa model dugaan sementara untuk data tersebut adalah ARIMA (0,1,1) (0,1,1)¹² atau ARIMA (0,1,1) (1,1,0)¹²

Berikut pemodelan data dengan menggunakan ARIMA (0,1,1) (0,1,1)¹²

```
> #terdapat beberapa dugaan model ARIMA sementara yaitu ARIMA(0,1,1)(0,1,1),period=12
> fit3 <- arima(Penjualan, order=c(0,1,1),seasonal=list(order=c(0,1,1),period=12),method="ML")
> fit3

Call:
arima(x = Penjualan, order = c(0, 1, 1), seasonal = list(order = c(0, 1, 1),
  period = 12), method = "ML")

Coefficients:
      ma1      sma1
    -0.2203   -0.6214
s.e.    0.0748    0.0627

sigma^2 estimated as 52.7:  log likelihood = -530.15,  aic = 1066.3
> |
```

Diperoleh nilai estimasi parameter MA1 = -0,2203 dan estimasi parameter SMA1 = -0,6214 dengan nilai AIC = 1066,3

Langkah berikutnya:

a. Melakukan diagnostic checking yaitu uji kesignifikanan parameter sebagai berikut:

```
> #Diagnostic Checking
> #1. Uji kesignifikanan parameter: Uji t
> coeftest(fit3)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.220348   0.074767  -2.9471  0.003207 **
sma1  -0.621388   0.062656  -9.9175 < 2.2e-16 ***
---
signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> |
```

Berdasarkan hasil R, taksiran parameter model MA(1) adalah signifikan berbeda dari nol. Hal ini dapat dilihat pada nilai $Pr(>|z|) < 0.003207 < \alpha = 0,01$. Taksiran parameter model SMA(1) adalah signifikan berbeda dari nol. Hal ini dapat dilihat pada nilai $Pr(>|z|) < 2.2e-16 < \alpha = 0,01$. Pengujian signifikan jika $Pr(>|z|) < \alpha$ dan pengujian tidak signifikan jika $Pr(>|z|) \geq \alpha$.

b. Pengujian residual White noise melalui L-Jung Box test:

```

> #2. pengujian residual apakah white noise
> Box.test(fit3$residuals, type="Ljung")

      Box-Ljung test

data:  fit3$residuals
X-squared = 0.012193, df = 1, p-value = 0.9121

> |

```

Dapat dilihat bahwa nilai p-value, criteria kesimpulannya adalah menolak H0 yang menyatakan residual white noise, jika p-value < * dan menerima H0 jika p-value > **. Berdasarkan hasil output pengujian residual Ljung Box diperoleh p-value = 0,9121 > * = 0,01 yang berarti bahwa gagal tolak H0. Sehingga dapat disimpulkan bahwa residual white noise.

c. Pengujian residual berdistribusi normal

```

> #3. Pengujian residual apakah berdistribusi normal
> shapiro.test(fit3$residuals)

      Shapiro-Wilk normality test

data:  fit3$residuals
W = 0.96515, p-value = 0.0003192

> |

```

```

> #Shapiro-Francia normality test
> sf.test(fit3$residuals)

      Shapiro-Francia normality test

data:  fit3$residuals
W = 0.96182, p-value = 0.0002993

> |

```

Berdasarkan hasil output pengujian normalitas diperoleh nilai p-value < 1 = 0,01 yang berarti bahwa tolak H0. Jadi dapat disimpulkan bahwa residual tidak memenuhi asumsi distribusi normal.

Untuk ARIMA 0,1,1) (1,1,0)¹²

Alternatif model ARIMA 0,1,1) (1,1,0)¹²

```

> #Alternative model ARIMA(0,1,1)(1,1,0), period=12
> fit4<-arima(Penjualan, order=c(0,1,1), seasonal=list(order=c(1,1,0),period=12),method="ML")
> fit4

Call:
arima(x = penjualan, order = c(0, 1, 1), seasonal = list(order = c(1, 1, 0),
  period = 12), method = "ML")

Coefficients:
      ma1      sar1
    -0.2284  -0.4551
s.e.    0.0724   0.0713

sigma^2 estimated as 59.54:  log likelihood = -538.06,  aic = 1082.13
> |

```

1. Diagnostik Checking

```

> #Diagnostic Checking
> #1. Uji kesignifikanan parameter: Uji t
> coeftest(fit4)

z test of coefficients:

      Estimate Std. Error z value Pr(>|z|)
ma1  -0.228415   0.072445 -3.1529  0.001616 **
sar1  -0.455113   0.071321 -6.3812  1.757e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> |

```

2. Pengujian residual white noise

```

> #2. pengujian residual apakah white noise
> Box.test(fit4$residuals, type="Ljung")

Box-Ljung test

data:  fit4$residuals
X-squared = 0.04457, df = 1, p-value = 0.8328

> |

```

3. Pengujian residual berdistribusi normal

```

> #3. Pengujian residual apakah berdistribusi normal
> shapiro.test(fit4$residuals)

shapiro-wilk normality test

data:  fit4$residuals
W = 0.95959, p-value = 8.768e-05

> |

```

```
> #Shapiro-Francia normality test
> sf.test(fit4$residuals)

Shapiro-Francia normality test

data: fit4$residuals
W = 0.9538, p-value = 6.613e-05

> |
```

Untuk menentukan model terbaik, dipilih model dengan nilai AIC terkecil. Nilai AIC untuk model ARIMA (0,1,1) (1,1,0)¹² adalah 1066,3 sedangkan nilai AIC untuk model ARIMA (0,1,1) (0,1,1)¹² adalah 1082,13. Jadi dapat ditarik kesimpulan bahwa model Arima yang terbaik adalah ARIMA (0,1,1) (0,1,1)¹²

3. Forecasting

Tahap peramalan dilakukan dengan menggunakan model terbaik yaitu model ARIMA (0,1,1) (0,1,1)¹²

```
> #Forecasting untuk 12 tahap kedepan berdasarkan model terbaik
> forecasting <- forecast(Penjualan, model=fit3, h=12)
> forecasting
```

	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
169	865.9773	856.6736	875.2810	851.7486	880.2061
170	818.7492	806.9520	830.5464	800.7070	836.7915
171	925.4057	911.5569	939.2544	904.2258	946.5855
172	938.4836	922.8502	954.1170	914.5744	962.3929
173	1001.6235	984.3893	1018.8577	975.2660	1027.9810
174	974.2165	955.5180	992.9150	945.6196	1002.8134
175	932.8502	912.7940	952.9063	902.1769	963.5234
176	893.2598	871.9323	914.5874	860.6422	925.8775
177	847.3679	824.8406	869.8952	812.9154	881.8205
178	852.5327	828.8664	876.1990	816.3382	888.7272
179	818.4932	793.7402	843.2462	780.6368	856.3496
180	860.7535	834.9596	886.5474	821.3052	900.2019


```
> |
```

Hasil ramalan penjualan untuk hari ke 169 sampai hari ke 180 diberikan. Sehingga hasil ramalan penjualan hari ke 169 adalah 864,9773 dan ramalan penjualan hari ke 180 adalah 859,7535.

Berikutnya ditampilkan plot

```
> plot(forecasting, main="Plot Hasil Peramalan")
> |
```

Plot Hasil Peramalan



- a. Lakukan metodologi Box-Jenkins untuk menentukan model ARIMA terbaik yang sesuai untuk data tersebut! Apakah data tersebut sudah stasioner dalam variansi? Tuliskan nilai Boxcox.lambda yang diperoleh! Lampirkan hasil komputer yang diperoleh!

Jawab:

- Data sebelumnya belum stasioner dalam variansi sehingga diperlukan differencing¹.

Jadi nilai untuk boxcox.lambdayaitu 1.17999

```
> BoxCox.lambda(Penjualan)
[1] 1.17999
```

- Untuk menentukan model terbaik, dipilih model dengan nilai AIC terkecil. Nah untuk nilai AIC untuk model ARIMA (0,1,1) (1,1,0)¹² adalah 1066,3 sedangkan nilai AIC untuk model ARIMA (0,1,1) (0,1,1)¹² adalah 1082,13. Jadi dapat disimpulkan bahwa model yang terbaik adalah ARIMA (0,1,1) (0,1,1)¹²

- b. Lakukan peramalan untuk menentukan nilai-nilai 12 tahap ke depan!

Jawab:

Hasil dari syntax diatas yaitu:

```
> #Forecasting untuk 12 tahap kedepan berdasarkan model terbaik
> forecasting <- forecast(Penjualan, model=fit3, h=12)
> forecasting
```

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
169		865.9773	856.6736	875.2810	851.7486	880.2061
170		818.7492	806.9520	830.5464	800.7070	836.7915
171		925.4057	911.5569	939.2544	904.2258	946.5855
172		938.4836	922.8502	954.1170	914.5744	962.3929
173		1001.6235	984.3893	1018.8577	975.2660	1027.9810
174		974.2165	955.5180	992.9150	945.6196	1002.8134
175		932.8502	912.7940	952.9063	902.1769	963.5234
176		893.2598	871.9323	914.5874	860.6422	925.8775
177		847.3679	824.8406	869.8952	812.9154	881.8205
178		852.5327	828.8664	876.1990	816.3382	888.7272
179		818.4932	793.7402	843.2462	780.6368	856.3496
180		860.7535	834.9596	886.5474	821.3052	900.2019

```
> |
```

Hasil ramalan penjualan untuk hari ke 169 sampai hari ke 180 diberikan. Jadi dapat disimpulkan bahwa hasil ramalan penjualan hari ke 169 adalah 864,9773 dan ramalan penjualan hari ke 180 adalah 859,7535. Plot hasil ramalan sebagai berikut:

Plot Hasil Peramalan

